


1.2 Importer les données

Récupération, analyse et visualisation de données numériques

UniGe – A.A. 2024/2025



Formats de données


Dans tout projet d'analyse de données, une grande partie du temps est consacrée à la préparation des données pour l'analyse. Il s'agit notamment de lire les formats de données (« legacy data »), de stocker les données dans des fichiers intermédiaires, d'enregistrer les données dans une base de données pour un stockage à plus long terme.

Nous nous concentrerons sur les **formats principaux** suivants :

- CSV
- XML
- JSON

CSV

- CSV: comma separated values
- TSV: tab separated values
- La lingua franca des données tabulaires
- Première ligne : en-têtes de colonne



The screenshot shows a GitHub repository for 'ADA-DHOxSS2019'. The file 'elonmusk_tweets.csv' is selected, showing its commit history and content. The CSV file contains 2821 lines of data with three columns: 'id', 'created_at', and 'text'. The 'text' column contains tweets from Elon Musk.

	id	created_at	text
1			
2	849636868052275200	2017-04-05 14:56:29	b'And so the robots spared humanity ... https://t.co/v7JUJQWfCv'
3	848998730585096192	2017-04-03 20:01:01	b'@Forin2020 @walmartssberg @mims @defcon_5 Exactly. Tesla is absurdly overvalued if based on the past, b
4	848943072423497728	2017-04-03 16:59:35	b'@walmartssberg @mims @defcon_5 Et tu, Walt?'
5	848935705057280001	2017-04-03 16:30:19	b'Stormy weather in Shortville ...'
6	848416049573658624	2017-04-02 06:05:23	b'@DaveLeeBBC @verge Coal is dying due to nat gas fracking. It's basically dead.'
7	848415731502923777	2017-04-02 06:04:07	b'@Lexxxis It's just a helicopter in helicopter's clothing"
8	848415356263702528	2017-04-02 06:02:38	b'@verge It won't matter"
9	848398971139629057	2017-04-02 04:57:31	b'@SuperCoolCube Pretty good'
10	848244577521647616	2017-04-01 18:44:01	b'Why did we waste so much time developing silly rockets? Damn you, aliens! So obtuse! You have all this craz
11	848243350993895424	2017-04-01 18:39:09	b'Technology breakthrough: turns out chemtrails are actually a message from time-traveling aliens describing
12	848239928043491328	2017-04-01 18:25:33	b'RT @OpenAI: We've created the world's first Spam-detecting AI trained entirely in simulation and deployed c

Quelques **inconvénients** :

- Les caractères des colonnes de texte bruyantes peuvent interférer avec les séparateurs (utiliser TSV).
- L'information sur le type de données n'est pas stockée dans le fichier (contrairement à Parquet, par exemple).

XML

eXtensible Markup Language

Descriptive markup: Balisage descriptif : accent mis sur le **contenu** (données) plutôt que sur sa **présentation** (interface).

Extensible : il n'y a pas de jeu de balises prédéfini.

Les documents XML :

- doivent être bien formés (le document a une racine ; tous les éléments ferment la balise, etc.)
- doivent être validés par rapport à un schéma (la structure d'abord !)

XML

Elements

(1) `<l>The sun does arise, </l>`

(2) `<br />`

(3) `<lg>`

```
    <l>The sun does arise, </l>
</lg>
```

Attributes

- Element
- Attribute
- attribute value

```
<lg type="stanza">
```

```
<div2 type="poem" xml:id="d6">
  <head>The Ecchoing Green</head>
  <lg type="stanza">
    <l>The Sun does arise, </l>
    <l>And make happy the skies; </l>
    <l>The merry bells ring </l>
    <l>To welcome the Spring; </l>
    <l>The sky-lark and thrush, </l>
    <l>The birds of the bush, </l>
    <l>Sing louder around </l>
    <l>To the bells' chearful sound, </l>
    <l>While our sports shall be seen </l>
    <l>On the Ecchoing Green. </l>
  </lg>
  <lg type="stanza">
    <l>Old John, with white hair, </l>
    <l>Does laugh away care, </l>
```

Mixing vocabularies:

Declaration of namespaces in the root element

```
<root xmlns:tei="http://www.tei-c.org/ns/1.0">
<tei:lg>
```

XML

Technologies:

- *Presentation* → CSS
- *Transformation* → XSLT
- *Navigation* → XPath
- *Query* → XQuery

XML in the wild:

- TEI (Text Encoding Initiative) XML
- MARCXML (library catalogue data)
- RDF XML
- ALTO XML (OCR data)
- GraphML
- ...

JSON

JavaScript Object Notation

Data types:

- Number
- String: any sequence of zero or more Unicode characters
- Boolean: true | false
- Array (list in Python)
- Object: unordered collection of name-value pairs {"title": "ADA DHOxSS"}

```
{
  '_id' : 1,
  'name' : { 'first' : 'John', 'last' : 'Backus' },
  'contribs' : [ 'Fortran', 'ALGOL', 'Backus-Naur Form', 'FP' ],
  'awards' : [
    {
      'award' : 'W.W. McDowell Award',
      'year' : 1967,
      'by' : 'IEEE Computer Society'
    }, {
      'award' : 'Draper Prize',
      'year' : 1993,
      'by' : 'National Academy of Engineering'
    }
  ]
}
```

<https://www.mongodb.com/json-and-bson>

JSON

- Need for structure: JSON schema
- Databases that *speak* JSON: ElasticSearch, MongoDB, etc.
- JSON-LD: Web-friendly format to encode RDF data

Travailler avec des formats de données

Dans l'ADA, la plupart du temps, nous **ne pouvons pas choisir** le format des données avec lesquelles nous travaillons.

Mais, si c'est à vous de choisir, tenez compte de ce qui suit :

- L'**utilisation visée** (analyse, présentation en ligne, etc.)
- La **communauté cible** (grand public, chercheurs, scientifiques des données)
- **Formats multiples** pour des scénarios d'utilisation multiples (utilisation interne, publication de données, application web, etc.)